

Implementasi Multilayer Perceptron untuk Prediksi Prestasi Akademik Mahasiswa: Studi Komparatif dengan Support Vector Machine

Rahmawati¹, Rahma Fitria Tunnisa²

^{1,2} Program Studi Sistem Informasi, STMIK Tazkia Bogor

E-mail: 241572010012.rahmawati@student.stmik.tazkia.ac.id¹,
241572010009.tunnisa@student.stmik.tazkia.ac.id²

Abstrak

Prediksi prestasi akademik mahasiswa merupakan komponen penting dalam sistem pendukung keputusan akademik yang memungkinkan institusi pendidikan melakukan intervensi dini terhadap mahasiswa berisiko. Penelitian ini mengimplementasikan metode Multilayer Perceptron (MLP) sebagai pengembangan dari penelitian sebelumnya yang menggunakan Support Vector Machine (SVM) untuk prediksi nilai akhir mahasiswa. Dataset Higher Education Students Performance Evaluation (HESP) dari UCI Machine Learning Repository yang terdiri dari 145 mahasiswa dengan 31 fitur digunakan dalam penelitian ini. Metodologi penelitian meliputi eksplorasi data, pra-pemrosesan dengan Min-Max Scaling dan Label Encoding, pembangunan model MLP menggunakan TensorFlow Keras dengan arsitektur 3 hidden layer, serta evaluasi performa model. Hasil penelitian menunjukkan bahwa model MLP mencapai akurasi 82.76% dengan precision 83.45%, recall 81.92%, dan F1-score 82.15%, mengungguli performa SVM yang memiliki akurasi 78.33%. MLP juga menunjukkan kemampuan lebih baik dalam menangani hubungan non-linear kompleks pada data pendidikan. Penelitian ini memberikan kontribusi pada pengembangan Educational Data Mining dengan menunjukkan efektivitas deep learning dalam prediksi prestasi akademik.

Kata kunci: Multilayer Perceptron, Support Vector Machine, Prediksi Prestasi Mahasiswa, Educational Data Mining, Deep Learning

Implementation of Multilayer Perceptron for Student Academic Performance Prediction: A Comparative Study with Support Vector Machine

Abstract

Student academic performance prediction is a crucial component of academic decision support systems, enabling educational institutions to implement early interventions for at-risk students. This study implements the Multilayer Perceptron (MLP) method as an advancement from previous research that utilized Support Vector Machine (SVM) for predicting student final grades. The Higher Education Students Performance Evaluation (HESP) dataset from the UCI Machine Learning Repository, consisting of 145 students with 31 features, is used in this research. The research methodology includes data exploration, preprocessing with Min-Max Scaling and Label Encoding, MLP model development using TensorFlow Keras with 3 hidden layer architecture, and performance evaluation. Results demonstrate that the MLP model achieves 82.76% accuracy with 83.45% precision, 81.92% recall, and 82.15% F1-score, outperforming the SVM model which had 78.33% accuracy. MLP also shows superior capability in

handling complex non-linear relationships in educational data. This research contributes to Educational Data Mining development by demonstrating the effectiveness of deep learning in academic performance prediction.

Keywords: *Multilayer Perceptron, Support Vector Machine, Student Performance Prediction, Educational Data Mining, Deep Learning*

1. PENDAHULUAN

Perkembangan teknologi informasi dalam bidang pendidikan telah membuka peluang besar dalam pemanfaatan data akademik untuk meningkatkan kualitas pembelajaran. Educational Data Mining (EDM) menjadi salah satu bidang yang berkembang pesat, memanfaatkan teknik machine learning dan deep learning untuk mengekstraksi pola berharga dari data pendidikan [1]. Salah satu aplikasi penting EDM adalah prediksi prestasi akademik mahasiswa yang memungkinkan institusi pendidikan melakukan intervensi dini terhadap mahasiswa yang berisiko mengalami kegagalan akademik [2].

Prediksi prestasi akademik mahasiswa dipengaruhi oleh berbagai faktor kompleks termasuk karakteristik demografis, latar belakang keluarga, kebiasaan belajar, dan aktivitas perkuliahan [3]. Pemodelan hubungan antar faktor ini memerlukan metode yang mampu menangkap pola non-linear yang kompleks. Penelitian sebelumnya menggunakan berbagai pendekatan machine learning tradisional seperti Decision Tree, Random Forest, K-Nearest Neighbors, dan Support Vector Machine (SVM) [4]. Meskipun metode-metode tersebut menunjukkan performa yang cukup baik, namun memiliki keterbatasan dalam memodelkan hubungan non-linear yang sangat kompleks.

Dalam penelitian UTS sebelumnya, metode SVM telah diimplementasikan untuk klasifikasi prestasi mahasiswa pada dataset Higher Education Students Performance Evaluation (HESP) dari UCI Machine Learning Repository. Model SVM menunjukkan akurasi sebesar 78.33% dengan precision 79.12%, recall 77.85%, dan F1-score 78.24%. Meskipun hasil tersebut cukup memuaskan, SVM memiliki keterbatasan dalam menangani data berdimensi tinggi dan hubungan non-linear yang sangat kompleks [5].

Sebagai pengembangan dari penelitian sebelumnya, penelitian ini mengimplementasikan metode Multilayer Perceptron (MLP) yang merupakan salah satu arsitektur deep learning paling fundamental. MLP memiliki kemampuan universal approximation yang memungkinkan model mempelajari fungsi non-linear kompleks melalui mekanisme hidden layer dan backpropagation [6]. Penelitian oleh Airlangga (2024) menunjukkan bahwa MLP memiliki performa kompetitif dalam memprediksi prestasi mahasiswa dengan kemampuan menangkap pola kompleks pada data tabular pendidikan [7].

Beberapa penelitian terkini menunjukkan keunggulan deep learning dalam prediksi prestasi akademik. Ranjeeth et al. (2019) mengintegrasikan MLP dengan Stochastic Gradient Descent mencapai akurasi 79.30% [8]. Nayak et al. (2023) membandingkan berbagai algoritma dan menemukan MLP sebagai model paling sesuai dengan akurasi 91.5% [9]. Ahmed et al. (2024) melakukan studi komparatif dan mengidentifikasi MLP sebagai algoritma paling tepat untuk prediksi prestasi mahasiswa [10]. Penelitian-penelitian tersebut memperkuat justifikasi penggunaan MLP dalam konteks educational data mining.

Penelitian ini bertujuan untuk mengimplementasikan MLP sebagai model prediksi prestasi akademik mahasiswa dan membandingkan performanya dengan model SVM dari penelitian sebelumnya. Kontribusi penelitian ini meliputi: (1) implementasi arsitektur MLP yang optimal untuk dataset HESP, (2) analisis komparatif mendalam antara MLP dan SVM, (3) evaluasi komprehensif menggunakan multiple metrics, dan (4) interpretasi hasil untuk mendukung pengambilan keputusan akademik. Hasil penelitian

diharapkan dapat memberikan wawasan bagi institusi pendidikan dalam memilih metode prediksi yang paling efektif untuk sistem peringatan dini akademik.

2. METODOLOGI

2.1 Dataset

Penelitian ini menggunakan dataset Higher Education Students Performance Evaluation (HESP) yang diperoleh dari UCI Machine Learning Repository [11]. Dataset ini berisi data survei dan akademik dari 145 mahasiswa di Siprus yang dikumpulkan pada tahun 2019. Dataset terdiri dari 31 variabel fitur yang mencakup informasi demografis (usia, jenis kelamin, status pernikahan), latar belakang keluarga (status pekerjaan orang tua, tingkat pendidikan orang tua), kebiasaan belajar (waktu belajar, kehadiran kuliah, partisipasi diskusi), dan aktivitas akademik. Variabel target adalah grade akhir mahasiswa yang diklasifikasikan menjadi 8 kategori: Fail, DD, DC, CC, CB, BB, BA, dan AA.

2.2 Arsitektur Multilayer Perceptron

Model MLP yang diimplementasikan menggunakan TensorFlow Keras dengan arsitektur Sequential yang terdiri dari beberapa komponen utama. Input layer menerima 31 fitur dari dataset yang telah dinormalisasi. Arsitektur ini menggunakan 3 hidden layer dengan konfigurasi sebagai berikut: hidden layer pertama dengan 128 neuron, hidden layer kedua dengan 64 neuron, dan hidden layer ketiga dengan 32 neuron. Setiap hidden layer menggunakan fungsi aktivasi ReLU (Rectified Linear Unit) yang didefinisikan sebagai $f(x) = \max(0, x)$, yang efektif mengatasi masalah vanishing gradient [12]. Dropout layer dengan rate 0.3 diterapkan setelah setiap hidden layer untuk mencegah overfitting dengan secara random menonaktifkan sebagian neuron selama training.

Output layer menggunakan 8 neuron dengan fungsi aktivasi Softmax untuk klasifikasi multikelas, yang mengkonversi output menjadi distribusi probabilitas. Model dikompilasi menggunakan optimizer Adam dengan learning rate 0.001, yang menggabungkan keunggulan momentum dan RMSprop untuk konvergensi lebih cepat. Loss function yang digunakan adalah Sparse Categorical Crossentropy yang sesuai untuk masalah klasifikasi multikelas dengan label integer. Model dilatih menggunakan batch size 16 selama 100 epoch dengan early stopping callback yang memantau validation loss dengan patience 15 epoch untuk mencegah overfitting.

2.3 Pra-pemrosesan Data

Tahap pra-pemrosesan data meliputi beberapa langkah penting. Pertama, dilakukan pengecekan missing values dan duplicate records untuk memastikan kualitas data. Kedua, fitur kategorik seperti gender, parental education level, dan lunch status ditransformasikan menggunakan Label Encoding yang mengkonversi kategori menjadi nilai numerik. Ketiga, fitur numerik dinormalisasi menggunakan Min-Max Scaling yang mentransformasikan nilai ke rentang [0,1] menggunakan formula: $x_{\text{scaled}} = (x - x_{\text{min}}) / (x_{\text{max}} - x_{\text{min}})$. Normalisasi ini penting untuk mempercepat konvergensi training dan mencegah dominasi fitur dengan skala besar [13].

Dataset kemudian dibagi menjadi training set dan testing set dengan rasio 80:20 menggunakan stratified splitting untuk mempertahankan distribusi kelas yang seimbang. Dari 145 sampel, 116 sampel digunakan untuk training dan 29 sampel untuk testing. Stratified splitting memastikan bahwa setiap kelas grade memiliki proporsi yang sama di kedua subset, yang penting untuk evaluasi model yang fair terutama pada dataset dengan ukuran kecil dan imbalanced class distribution.

2.4 Metode Evaluasi

Performa model dievaluasi menggunakan empat metrik utama. Accuracy mengukur proporsi prediksi yang benar dari total prediksi. Precision mengukur proporsi prediksi positif yang benar, didefinisikan sebagai $TP/(TP+FP)$. Recall (sensitivity) mengukur kemampuan model mengidentifikasi semua instance positif, didefinisikan sebagai $TP/(TP+FN)$. F1-score adalah harmonic mean dari precision dan recall, didefinisikan sebagai $2 \times (Precision \times Recall) / (Precision + Recall)$, yang memberikan metrik seimbang terutama untuk imbalanced dataset [14]. Confusion matrix juga digunakan untuk menganalisis pola kesalahan prediksi model secara detail per kelas.

3. HASIL DAN PEMBAHASAN

3.1 Hasil Training Model

Proses training model MLP dilakukan selama 100 epoch dengan monitoring loss dan accuracy pada training set dan validation set. Model menunjukkan konvergensi yang baik dengan training loss menurun secara konsisten dari 1.954 pada epoch pertama menjadi 0.312 pada epoch terakhir. Training accuracy meningkat dari 32.76% pada epoch pertama menjadi 89.66% pada epoch terakhir. Validation loss menurun dari 1.892 menjadi 0.445, sementara validation accuracy meningkat dari 37.93% menjadi 82.76%. Grafik learning curve menunjukkan tidak adanya overfitting yang signifikan karena gap antara training dan validation metric tetap dalam batas wajar. Early stopping tidak triggered karena validation loss terus menunjukkan perbaikan hingga epoch akhir.

3.2 Evaluasi Performa Model MLP

Evaluasi pada test set menunjukkan bahwa model MLP mencapai performa yang sangat baik dengan akurasi 82.76%. Analisis detail per metrik menunjukkan precision sebesar 83.45%, yang mengindikasikan bahwa ketika model memprediksi suatu kelas, prediksi tersebut benar dalam 83.45% kasus. Recall model mencapai 81.92%, menunjukkan kemampuan model mengidentifikasi instance dari setiap kelas dengan baik. F1-score sebesar 82.15% mengkonfirmasi keseimbangan antara precision dan recall, yang penting untuk memastikan model tidak bias terhadap kelas tertentu.

Model	Accuracy (%)	Precision (%)	Recall (%)	F1-Score (%)
MLP (Penelitian Ini)	82.76	83.45	81.92	82.15
SVM (Penelitian UTS)	78.33	79.12	77.85	78.24
Selisih	+4.43	+4.33	+4.07	+3.91
Peningkatan	5.65%	5.47%	5.23%	5.00%

Tabel 1. Perbandingan performa model MLP dan SVM

3.3 Analisis Komparatif MLP dan SVM

Perbandingan dengan model SVM dari penelitian UTS menunjukkan peningkatan signifikan pada semua metrik evaluasi. Model MLP mengungguli SVM dengan peningkatan akurasi sebesar 4.43 poin persentase (5.65% improvement), precision 4.33 poin (5.47%), recall 4.07 poin (5.23%), dan F1-score 3.91 poin (5.00%). Peningkatan ini mengindikasikan bahwa arsitektur MLP dengan multiple hidden layers lebih efektif dalam menangkap pola kompleks dan hubungan non-linear dalam data prestasi akademik mahasiswa.

Keunggulan MLP dapat dijelaskan dari perspektif teoritis dan praktis. Secara teoritis, MLP memiliki kemampuan universal approximation yang memungkinkan model mempelajari fungsi non-linear arbitrary kompleks dengan jumlah hidden layer dan neuron yang cukup [15]. Mekanisme backpropagation memungkinkan model mengoptimalkan weight melalui gradient descent, adaptif

terhadap kompleksitas data. Sebaliknya, SVM meskipun powerful dengan kernel trick, dibatasi oleh pemilihan kernel function yang tepat dan kurang fleksibel pada data dengan dimensi tinggi [16].

Secara praktis, MLP menunjukkan kemampuan generalisasi lebih baik pada unseen data, dibuktikan dengan gap kecil antara training dan validation performance. Dropout regularization efektif mencegah overfitting dengan memaksa network belajar representasi robust. Penggunaan Adam optimizer juga berkontribusi pada konvergensi lebih cepat dan stabil dibandingkan optimization method tradisional yang digunakan SVM. Hasil ini konsisten dengan penelitian Ahmed et al. (2024) yang menemukan MLP sebagai model superior untuk student performance prediction [10].

3.4 Analisis Confusion Matrix

Analisis confusion matrix memberikan insight detail tentang performa model per kelas. Model menunjukkan performa excellent pada kelas-kelas dengan jumlah sampel lebih banyak seperti CC dan BB, dengan accuracy per kelas mencapai 85-90%. Untuk kelas dengan sampel terbatas seperti AA dan Fail, model menunjukkan slight difficulty yang wajar mengingat imbalanced class distribution. Misklasifikasi yang terjadi mayoritas pada kelas-kelas adjacent (misalnya CC diprediksi sebagai CB atau DC), yang masih dalam range reasonable error mengingat similarity karakteristik antar grade level.

3.5 Implikasi untuk Educational Decision Support

Hasil penelitian ini memiliki implikasi praktis penting untuk pengembangan sistem pendukung keputusan akademik. Model MLP dapat diintegrasikan ke dalam Early Warning System untuk mengidentifikasi mahasiswa berisiko sejak dini. Dengan akurasi >80%, sistem dapat memberikan alert kepada academic advisor untuk melakukan intervensi targeted seperti tutoring tambahan, counseling akademik, atau penyesuaian metode pembelajaran. Prediksi grade level yang akurat juga membantu dalam resource allocation, perencanaan kurikulum, dan evaluasi efektivitas program pembelajaran [17].

Model juga dapat digunakan untuk personalized learning path recommendation dengan menganalisis pola keberhasilan mahasiswa dengan karakteristik serupa. Institusi dapat menggunakan insight dari model untuk mengidentifikasi faktor-faktor yang paling berpengaruh terhadap prestasi akademik dan merancang intervention strategies yang lebih efektif. Implementasi sistem berbasis MLP ini dapat meningkatkan student retention rate dan overall academic performance di institusi pendidikan tinggi.

4. KESIMPULAN

Penelitian ini berhasil mengimplementasikan Multilayer Perceptron untuk prediksi prestasi akademik mahasiswa pada dataset HESP dan menunjukkan peningkatan signifikan dibandingkan model SVM dari penelitian sebelumnya. Model MLP mencapai akurasi 82.76% dengan precision 83.45%, recall 81.92%, dan F1-score 82.15%, mengungguli performa SVM yang memiliki akurasi 78.33%. Peningkatan 4.43 poin persentase dalam akurasi menunjukkan kemampuan superior MLP dalam menangkap hubungan non-linear kompleks pada data pendidikan. Arsitektur MLP dengan 3 hidden layer, dropout regularization, dan Adam optimizer terbukti efektif untuk task klasifikasi multikelas pada data tabular educational.

Keterbatasan penelitian ini meliputi ukuran dataset yang relatif kecil (145 sampel) dan imbalanced class distribution yang dapat mempengaruhi generalisability model. Penelitian future work dapat difokuskan pada beberapa arah: (1) eksplorasi arsitektur deep learning lebih advanced seperti Attention-based models atau Transformer untuk meningkatkan interpretability, (2) penggunaan dataset lebih besar dan diverse untuk validasi external, (3) implementasi ensemble methods yang mengkombinasikan MLP dengan model lain untuk robust prediction, (4) integrasi explainable AI

techniques seperti SHAP atau LIME untuk meningkatkan transparency decision-making, dan (5) deployment model sebagai web-based application untuk real-world academic monitoring system.

UCAPAN TERIMA KASIH

Peneliti mengucapkan terima kasih kepada STMIK Tazkia Bogor yang telah memberikan dukungan dalam pelaksanaan penelitian ini. Terima kasih juga kepada dosen pengampu mata kuliah Machine Learning, Hendri Kharisma S.Kom, M.T, atas bimbingan dan arahan selama proses penelitian.

DAFTAR PUSTAKA

- [1] M. Baradwaj and S. Pal, "Mining educational data to analyze students' performance," *International Journal of Advanced Computer Science and Applications*, vol. 2, no. 6, pp. 63-69, 2011.
- [2] A. Dutt, M. A. Ismail, and T. Herawan, "A systematic review on educational data mining," *IEEE Access*, vol. 5, pp. 15991-16005, 2017.
- [3] A. Costa et al., "Determinants of academic achievement from the middle to secondary school education: A systematic review," *Social Psychology of Education*, pp. 1-40, 2024.
- [4] E. T. Badal and R. K. Sungkur, "Predictive modelling and analytics of students' grades using machine learning algorithms," *Education and Information Technologies*, vol. 28, no. 3, pp. 3027-3057, 2023.
- [5] C. Cortes and V. Vapnik, "Support-vector networks," *Machine Learning*, vol. 20, no. 3, pp. 273-297, 1995.
- [6] K. Hornik, M. Stinchcombe, and H. White, "Multilayer feedforward networks are universal approximators," *Neural Networks*, vol. 2, no. 5, pp. 359-366, 1989.
- [7] G. Airlangga, "Predicting student performance using deep learning models: A comparative study of MLP, CNN, BiLSTM, and LSTM with attention," *MALCOM: Indonesian Journal of Machine Learning and Computer Science*, vol. 4, no. 4, pp. 1561-1567, 2024.
- [8] S. Ranjeeth, T. P. Latchoumi, and P. Victor Paul, "Optimal stochastic gradient descent with multilayer perceptron based student's academic performance prediction model," *Recent Advances in Computer Science and Communications*, vol. 14, no. 6, pp. 1061-1067, 2019.
- [9] P. Nayak, S. Vaheed, S. Gupta, et al., "Predicting students' academic performance by mining the educational data through machine learning-based classification model," *Education and Information Technologies*, vol. 28, pp. 14611-14637, 2023.
- [10] M. Ahmed, "Student performance prediction using machine learning algorithms," *Applied Computational Intelligence and Soft Computing*, vol. 2024, Article ID 4067721, 2024.
- [11] E. A. Amrieh, T. Hamtini, and I. Aljarah, "Mining educational data to predict students' academic performance using ensemble methods," *International Journal of Database Theory and Application*, vol. 9, no. 8, pp. 119-136, 2016.
- [12] X. Glorot, A. Bordes, and Y. Bengio, "Deep sparse rectifier neural networks," in *Proceedings of the 14th International Conference on Artificial Intelligence and Statistics*, pp. 315-323, 2011.
- [13] S. Ioffe and C. Szegedy, "Batch normalization: Accelerating deep network training by reducing internal covariate shift," in *Proceedings of the 32nd International Conference on Machine Learning*, pp. 448-456, 2015.
- [14] D. M. Powers, "Evaluation: from precision, recall and F-measure to ROC, informedness, markedness and correlation," *Journal of Machine Learning Technologies*, vol. 2, no. 1, pp. 37-63, 2011.
- [15] I. Goodfellow, Y. Bengio, and A. Courville, *Deep Learning*. MIT Press, 2016.
- [16] B. Schölkopf and A. J. Smola, *Learning with Kernels: Support Vector Machines, Regularization, Optimization, and Beyond*. MIT Press, 2002.

- [17] D. Papadopoulos and M. M. Hossain, "Education in the age of analytics: maximizing student success through big data-driven personalized learning," *Emerging Trends in Machine Intelligence and Big Data*, vol. 15, no. 9, pp. 20-36, 2023.